maum Academy
AI Professional Education

Level 2. How to customize AI engines

http://mindslab.ai

1. BERT MRC 구조
2. MRC Train/Test
3. MRC Inference
4. MRC 실습

maum Academy
AI Professional Education

BERT MRC

Bidirectional Encoder Representations from Transformers + Machine Reading Comprehension

BERT MRC 란

- Google에서 발표한 Transformer encoder 기반의 구조를 가진 사전학습 모델을 base로 학습한 Machine Reading Comprehension 모델

- Autoencoder 방식의 사전학습 방법을 사용하여 BERT 모델 학습
  (대량의 텍스트 데이터를 MLM(Masked Language Model), NSP(Next Sentence Prediction) 방식을 이용해 사전학습)

- 사전학습 된 모델에 MRC Task에 맞는 네트워크를 추가하여 학습

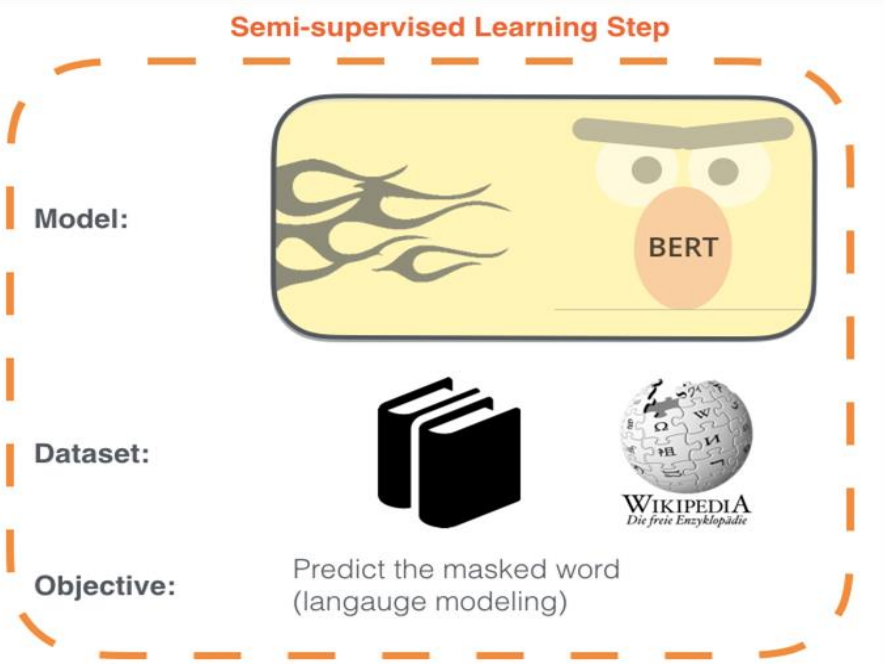

BERT MRC source

BERT MRC 한글 모델

학습 모델

- BERT MRC 아키텍처

vocab_size: 사전 수
max_position_embedding: 최대 시퀀스
num_attention_heads: 어텐션 헤드 수
num_hidden_layers: 트렌스포머 블록 수
hidden_size: 임베딩 크기

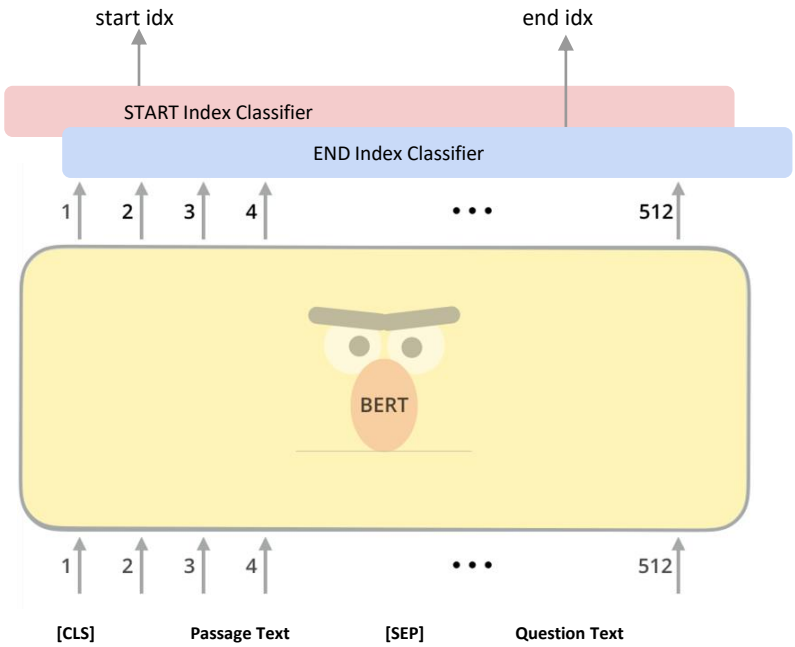


```
"vocab_size": 119547
"max_position_embeddings": 512,
"num_attention_heads": 12,
"num_hidden_layers": 12,
"hidden_size": 768,
```

maum Academy
AI Professional Education

BERT MRC source

BERT MRC source tree

Source tree

- core: mrc modules
  - additional_layers.py: mrc layers
  - evaluate_v1.py: mrc1.0 test metric
  - modeling.py: BERT modules
  - mrc_core.py: MRC modules
  - tokenization.py: BERT tokenizer
  - optimization.py: BERT optimizer
  - transform_data.py: convert input format

- models: 사전학습 모델 및 학습 모델

- mrc_client.py: serving client
- mrc_server.py: serving
- mrc_runner.sh: mrc 실행 shell

핵심 Command

- mrc_train.py: MRC 학습 명령어

- mrc_inference.py : MRC 실행 명령어
(학습한 모델 테스트)

```
.
├── README.md
├── core
│   ├── additional_layers.py
│   ├── evaluate_v1.py
│   ├── modeling.py
│   ├── mrc_core.py
│   ├── optimization.py
│   ├── tokenization.py
│   └── transform_data.py
├── models
│   ├── mrc_config.json
│   └── pretrained
│       ├── eng
│       │   ├── bert_config.json
│       │   ├── bert_model.ckpt.data-00000-of-00001
│       │   ├── bert_model.ckpt.index
│       │   ├── bert_model.ckpt.meta
│       │   └── vocab.txt
│       ├── kor
│       │   ├── bert_model.ckpt.data-00000-of-00001
│       │   ├── bert_model.ckpt.index
│       │   ├── bert_model.ckpt.meta
│       │   └── vocab.txt
│       └── multi
│           ├── bert_config.json
│           ├── bert_model.ckpt.data-00000-of-00001
│           ├── bert_model.ckpt.index
│           ├── bert_model.ckpt.meta
│           └── vocab.txt
├── mrc_client.py
├── mrc_inference.py
├── mrc_runner.sh
├── mrc_server.py
├── mrc_train.py
├── proto
│   └── mrc.proto
└── test
    ├── sample_data
    │   ├── test_en_long_out.txt
    │   ├── test_en_mid_out.txt
    │   ├── test_en_short_out.txt
    │   ├── test_ko_long_out.txt
    │   ├── test_ko_mid_out.txt
    │   └── test_ko_short_out.txt
    ├── test_benchmark_en.py
    ├── test_benchmark_ko.py
    ├── test_en.py
    └── test_ko.py
```

BERT MRC

BERT MRC Workflow

BERT MRC 학습 및 실행 Process

- 기본적으로 아래와 같이 3단계로 진행하며, 성능 안정화가 될 때까지 반복 작업

1. BERT MRC 구조
2. MRC Train/Test
3. MRC Inference
4. MRC 실습

MRC Train

MRC 학습 데이터

MRC 학습 데이터
- 문서 – 질문 – 정답 쌍 데이터
- json format(필수 O)

KorQuAD json 구조

['data']
- ['paragrahs']
  - ['qas']
    - ['answers']
      - ['answer_start'] : 시작 위치
      - ['text'] : 정답 텍스트
    - ['id'] : 이 질문/정답 쌍의 일련번호
    - ['question'] : 질문 텍스트
  - ['context'] : 문서 본문 텍스트

* 각 list에는 다수의 값이 들어감

[참고] 데이터 파일 예시


```
{'paragraphs': [{'context': '1989년 2월 15일 여의도 농민 폭력 시위를 주도한 혐의(폭력행위등처벌에관한법률위반)으로 지명수배되었다. 1989년
   'qas': [{'answers': [{'answer_start': 0, 'text': '1989년 2월 15일'}],
     'id': '6548850-0-0',
     'question': '임종석이 여의도 농민 폭력 시위를 주도한 혐의로 지명수배 된 날은?'},
    {'answers': [{'answer_start': 125, 'text': '임수경'}],
     'id': '6548850-0-1',
     'question': '1989년 6월 30일 평양축전에 대표로 파견 된 인물은?'},
```

maum Academy
AI Professional Education

MRC Train

MRC 학습 데이터

데이터 전처리

- Mecab 기반 sentencepiece 사전 (models/345K에 제공)

- Bert tokenizer (tokenization.py)
  * 학습 및 Inference 실행 시 자동으로 적용됨

```
context: 1989년 2월 15일 여의도 농민 폭력 시위를 주도한 혐의(폭력행위등처벌에관한법률위반)으로 지명수배되었다. 1989년

question: 임종석이 여의도 농민 폭력 시위를 주도한 혐의로 지명수배 된 날은?

answers [{'text': '1989년 2월 15일', 'answer_start': 0}]
```

```
context: 알렉산더 메이그스 헤이그 2세(영어: Alexander Meigs Haig, Jr., 1924년 12월 2일 ~ 2010년 2월 20일)는 미국의

question: 미국 군대 내 두번째로 높은 직위는 무엇인가?

answers [{'text': '미국 육군 부참모 총장', 'answer_start': 204}]
```

MRC Train

MRC Train Arguments

mrc_train.py 명령 옵션 (1/2)

```
parser.add_argument('--model_name', type=str, required=True)
parser.add_argument('-b', '--train_batch_size', type=int, default=8)
parser.add_argument('-l', '--max_seq_length', type=int, default=384)
parser.add_argument('-i', '--num_train_epochs', type=float, default=2.0)
```

- model_name: 학습 시키려는 모델 이름

- train_batch_size: 학습 시 minibatch 크기

- max_seq_length: 모델이 읽게 되는 데이터의 최대 길이(token 기준)

(batch 와 length는 GPU ram 크기에 맞게 설정,
1080ti GPU 기준 length 384 일 때 batch_size 6으로 학습 가능)

- num_train_epochs: 학습 진행 횟수

MRC Train

MRC Train Arguments

mrc_train.py 명령 옵션 (2/2)

```
parser.add_argument('-t', '--train', action='store_true', default=False)
parser.add_argument('-e', '--en', action='store_true', default=False)
parser.add_argument('-m', '--model_type', type=int, default=3)
parser.add_argument('--train_file', type=str, default=None)
parser.add_argument('--dev_file', type=str, default=None)
```

- train: 학습 시 옵션 표시
- en: 데이터 언어 설정으로 영어인 경우 옵션 표시
- model_type: 모델 종류
- train_file: 학습 데이터 경로 입력
- dev_file: 테스트 데이터 경로 입력

maum Academy
AI Professional Education

MRC Train

Run MRC Train

영어 데이터 학습 command 예시

```
python mrc_train.py  ₩
--model_name {모델 이름} ₩
--train_batch_size 6 ₩
--max_seq_length 384 ₩
--num_train_epochs 2.0 ₩
--train ₩
--en ₩
--train_file {학습 데이터 경로}
```

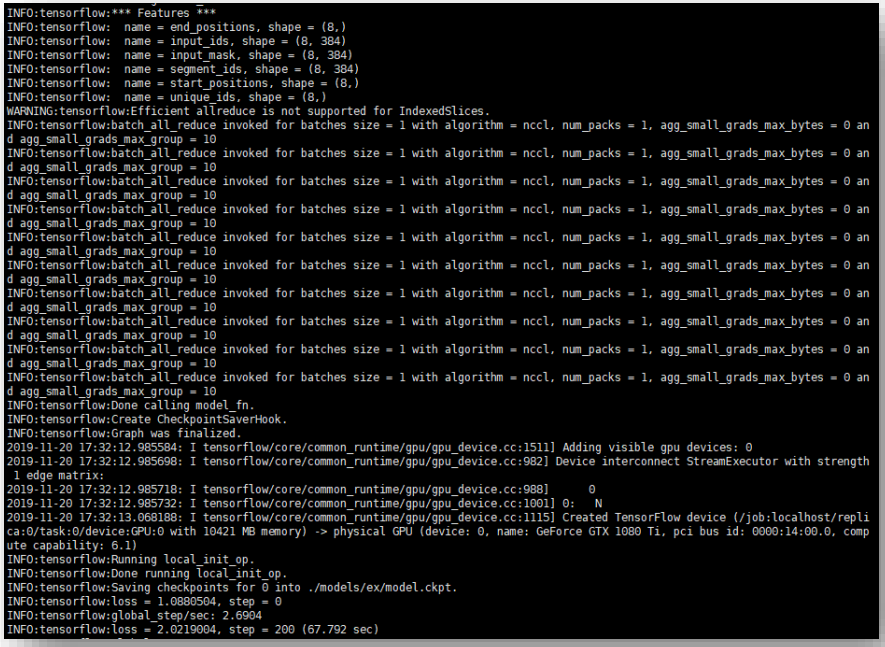

maum Academy
AI Professional Education

MRC Test

Run MRC Test

한글 데이터 테스트 command 예시

```
python mrc_train.py  ₩
--model_name {모델 이름} ₩
--train_batch_size 6 ₩
--max_seq_length 384 ₩
--num_train_epochs 2.0 ₩
--dev_file {테스트 데이터 경로}
```

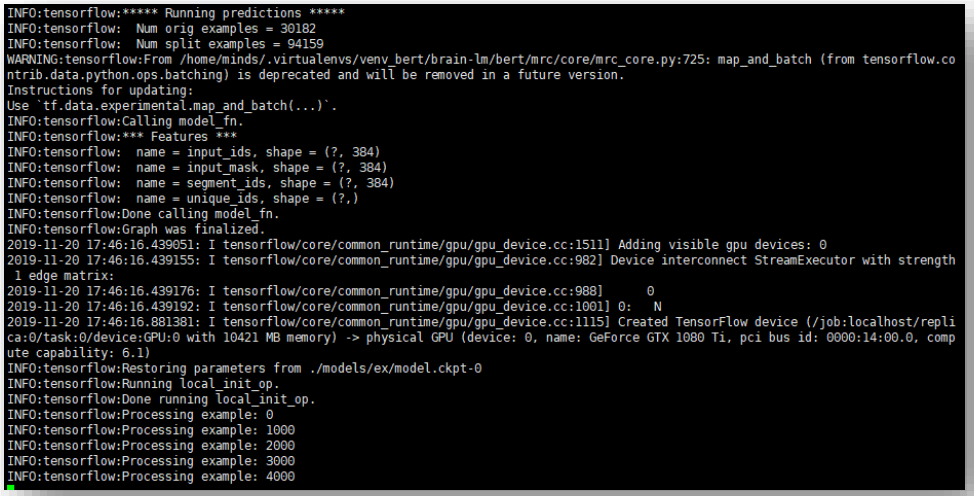

1. BERT MRC 구조

2. MRC Train/Test

3. MRC Inference

4. MRC 실습

MRC Inference

MRC Inference Arguments

mrc_inference.py 명령 옵션 (1/1)

```
parser.add_argument('--model_name', type=str, required=True)
parser.add_argument('-p', '--context', type=str, default=None)
parser.add_argument('-q', '--question', type=str, default=None)
parser.add_argument('-d', '--device', type=int, default=0)
parser.add_argument('-e', '--en', action='store_true', default=False)
```

- model_name: 학습된 모델 경로 입력
- context: 문서 내용 입력
- question: 질문 내용 입력
- device: 사용 GPU 번호
- en: 영어 모델 여부

maum Academy
AI Professional Education

MRC Inference

Run MRC Inference

한글 모델 Inference command 예시

```
python mrc_inference.py ₩
--model_name {모델 이름} ₩
--context {본문 내용} ₩
--question {질문 내용} ₩
--device {gpu id} ₩
#--en
```

```
2019-11-20 18:08:31.436121: I tensorflow/core/platform/cpu_feature_guard.cc:141] Your CPU supports instructions that this TensorFlow
 binary was not compiled to use: AVX2 FMA
2019-11-20 18:08:35.712461: I tensorflow/core/common_runtime/gpu/gpu_device.cc:1432] Found device 0 with properties:
name: GeForce GTX 1080 Ti major: 6 minor: 1 memoryClockRate(GHz): 1.582
pciBusID: 0000:14:00.0
totalMemory: 10.92GiB freeMemory: 10.77GiB
2019-11-20 18:08:35.712543: I tensorflow/core/common_runtime/gpu/gpu_device.cc:1511] Adding visible gpu devices: 0
2019-11-20 18:08:38.971485: I tensorflow/core/common_runtime/gpu/gpu_device.cc:982] Device interconnect StreamExecutor with strength
 1 edge matrix:
2019-11-20 18:08:38.971551: I tensorflow/core/common_runtime/gpu/gpu_device.cc:988]      0
2019-11-20 18:08:38.971568: I tensorflow/core/common_runtime/gpu/gpu_device.cc:1001] 0:   N
2019-11-20 18:08:38.972016: I tensorflow/core/common_runtime/gpu/gpu_device.cc:1115] Created TensorFlow device (/job:localhost/repli
ca:0/task:0/device:GPU:0 with 10421 MB memory) -> physical GPU (device: 0, name: GeForce GTX 1080 Ti, pci bus id: 0000:14:00.0, comp
ute capability: 6.1)
['김영란법(부정청탁 및 금품수수 금지법)시행 이후 맞은 첫 주말인 지난 1일 오후 6시쯤, 기자는 서울 서초구 G공익신고학원을 찾아갔다. 김
영란법 위반자를 적발해 포상금을 받는 방법을 알려 주는 일명 관파라치(김영란법+파파라치) 양성 학원이다. 교육 수강생 이모(56자영업)씨와
 박모(57퇴직자)씨가 다소 긴장한 표정으로 앉아 있었다.두 사람은 최근 이 학원에서 김영란법 위반자를 손쉽게 단속할 수 있는 비법 등 이른
 교육(총 3시간 30분)을 받은 수강생이다. 이들은 이날 서울의 한 병원 장례식장으로 첫 현장 출동을 앞둔 상황이었다.이 학원의 운영육 대표
가 몰래카메라 사용법과 현장활동 주의사항을 전달했다. 몰래카메라는 소매 끝 안쪽에 숨겨 촬영이 가능한 형태였다.이 학원 강의실 한쪽 장
식장 안에는 안경부터 모자라이터명함지갑 등 다양한 형태의 몰래카메라가 진열돼 있었다. 학원 관계자들은 최근 일부 관파라치 학원이 수강
생들에게 몰래카메라를 시중가격보다 비싸게 팔았다는 비판 보도를 의식한 때문인지 가격은 철저히 함구했다.']
['김영란법이 뭐야']
OrderedDict([('text', '부정청탁 및 금품수수 금지법'), ('probability', 0.9975685906370428), ('start_index', 14), ('end_index', 25), (
'start_logit', 8.977004051208496), ('end_logit', 8.652633666992188), ('passage_idx', 0)])
```

1. BERT MRC 구조
2. MRC Train/Test
3. MRC Inference
4. MRC 실습

실습 주제

- 각자 준비한 데이터 셋을 모델에 읽혀 학습하고 Inference 해보기

- 데이터 셋 전처리 작업의 경우 모델 실행시 자동으로 이루어짐

- 정해진 json format에 맞게 데이터를 준비하는 것이 중요

maum Academy
AI Professional Education

MRC 실습

1. 개발 환경 접속

1) 서버에 접속

- Host : 182.162.19.7
- User : minds
- Password : xxxxxx

2) MRC Docker run

```
docker run -it -w /mrc -v /{local data volume}:/mrc/data --
gpus all --name={container name} ex_mrc:1.0.0-tf1-py3
```

```
pip install -r requirements.txt
```

2. 학습데이터 준비

1) Docker run 시 마운트한 볼륨에 json format의 준비된 데이터 위치

3. MRC 학습

학습데이터 경로 등 config 내용 및 Arguments를 정확히 설정하여 학습 명령어 실행
*실행 위치 : 기본 위치

설정 예시(mrc_runner.sh)

```
python mrc_train.py  ₩
--model_name ex ₩
--train_batch_size 6 ₩
--max_seq_length 384 ₩
--num_train_epochs 2.0 ₩
--train ₩
--train_file /data/train_data.json
```

학습 명령어 예시

```
sh mrc_runner.sh
```

4. MRC Inference

다양한 Arguments를 정확히 설정하여 Inference 명령어 실행

*실행 위치 : 기본 위치

명령어 예시

```
python mrc_inference.py ₩
--model_name ex ₩
--context '안녕하세요 마인즈랩입니다.' ₩
--question '누구?' ₩
--device 0 ₩
```

감사합니다.

MINDs Lab. AI Platform Company